第七章：生成內容的倫理問題與偏誤查核——演算法偏見反思、虛假資訊溯源與 SynthID 水印實戰

課程導讀

在過去六週的課程中，我們一步一腳印地構築了聯合國永續發展目標（Sustainable Development Goals，SDGs）數位內容專案的核心基石。回顧這段歷程：第 1 週與第 2 週，我們確立了小組專題方向，並透過 Google Gemini 的蘇格拉底式提問對話，挑戰既有前提、挖掘受眾真實痛點；第 3 週，我們進入 Google AI Studio，掌握解碼參數與 CRISP 結構化提示工程；第 4 週，大家運用 S-S-L-M 視覺提示維度與擴散模型，渲染出極具視覺張力的專題核心主視覺海報；第 5 週，我們藉由 Google NotebookLM 的知識接地（Grounding）技術，將官方白皮書與常民社群心聲轉譯為有憑有據的 Campaign 倡議主張；到了第 6 週，我們更運用 Google Search Grounding 檢索最新智財判例，透過模擬法庭攻防確立了「人類原創性控制」與「商業合理使用（Fair Use）」的法律防護網。

然而，當我們的專案通過了著作權法的檢驗、確認「不會被告侵權」之後，身為未來的數位內容創意總監，還有最後一道、也是最深層的考驗正等待著我們：

> **「在法律上完全合法的 AI 生成內容，在社會倫理與人類價值上，就一定是正當、公正且負責任的嗎？」**
> **「當我們讓 AI 生成一張『25 歲的未來自己』或『需要被幫助的弱勢族群』時，演算法在無形中替我們套上了什麼樣的審美霸權與社會偏見？」**
> **「在深度偽造（Deepfake）與假新聞氾濫的年代，當觀眾質疑我們的永續倡議海報只是另一場『AI 合成的公關漂綠（Greenwashing）』時，我們該如何證明內容的真實性與透明度？」**

俗話說：「法律是道德的最低底線。」在數位傳播與品牌行銷領域，許多令企業商譽一夕崩盤的公關危機，往往不是因為違反了《著作權法》，而是因為觸犯了社會大眾對「多元共融（Diversity, Equity, and Inclusion，DEI）」、「人性尊嚴」與「資訊誠信」的倫理期待。大型語言模型與多模態擴散模型雖然擁有驚人的生成能力，但它們的訓練數據來自於人類歷史長河中充滿結構性不平等、商業濾鏡與主流霸權的網際網路語料。如果創作者對模型的統計本質缺乏警覺，不加思索地採用 AI 產出的第一張圖或第一段話，我們就會在不知不覺中成為「演算法偏誤（Algorithmic Bias）」的共犯——在宣揚永續發展與社會正義的同時，反而加深了性別、族裔、年齡與外貌的刻板印象，甚至以冷冰冰的工業化標準抹殺了人類最珍貴的原創想像力。

本章作為第一階段「基礎探索與觀念驗證（第 1–8 週）」的壓軸篇章，將帶領同學們從技術底層與人文思辨雙軌並進，直面生成式 AI 的倫理挑戰。我們將透過一則引發全球教育界與家長震撼的真實社群案例，深度剖析演算法偏見如何規訓人類的未來想像；學習辨識 SDGs 倡議中最常踩中的三大倫理地雷；更重要的是，我們將親手操作 Google DeepMind 研發的革命性防偽技術—— **Google SynthID 隱形數位浮水印** 與 **Google 反向圖片搜尋（About this image）**，並結合 CRISP 與 S-S-L-M 架構實踐 **「去偏誤與包容性提示工程（De-biasing & Inclusive Prompting）」**，為小組專題完成期中考前的最後一塊關鍵拼圖！

貫穿本週學習的核心心法如下：

> **法律是創作的最低底線，倫理則是品牌的最高護城河。真正卓越的數位內容設計師，絕不讓演算法的「統計平均值」綁架人類的多元價值與想像力；而是懂得透過「去偏誤提示工程」打破刻板印象，並以「SynthID 防偽溯源與透明揭露」捍衛數位時代的公眾信任。**

本週課堂嚴格依循 1 小時 50 分鐘的標準三段式結構：

1. **第一階段（25 分鐘）：** 核心理論與案例思辨——演算法偏誤（Algorithmic Bias）的統計成因、「公立小學 6 歲女孩 AI 未來照」真實案例深度討論，以及 SDGs 永續傳播的三大倫理盲區。
2. **第二階段（25 分鐘）：** Google AI 工具操作示範——深偽與多模態幻覺危機、Google SynthID 隱形浮水印與 C2PA 內容憑證原理、Google 反向圖片搜尋（About this image）溯源查核，以及去偏誤提示工程實戰。
3. **第三階段（60 分鐘）：** PBL 小組實作工作坊與期中總體檢——演算法偏誤誘發與重構實驗、SynthID 與反向搜尋查核、擬定專案《負責任 AI 透明揭露聲明》、倫理紅隊同儕互評，以及第 1～7 週期中考前核心觀念總整理。

第一節：生成式 AI 的隱形偏見——從訓練資料偏誤到社會倫理反思

1.1 為什麼 AI 會有偏見？從機率分佈看演算法偏誤（Algorithmic Bias）

在第二章與第三章中，我們曾剖析過現代人工智慧與大型語言模型的底層運作邏輯：機器學習並非由工程師逐條手寫道德規則，而是讓神經網路從數十億筆網際網路文本與影像資料中，自主歸納出特徵與詞彙之間的條件機率分佈；而在第四章中，我們也了解到擴散模型（Diffusion Model）是在高維度潛在空間（Latent Space）中，依據文字提示詞的語意引導，將隨機雜訊一步步「去噪」還原為高機率密度的視覺特徵。

許多初學者常有一種天真的迷思，認為：「人類會有主觀偏見，但電腦只看數學與數據，所以 AI 做出來的結果一定最客觀、最中立。」然而，計算機科學界有一句至理名言：**「垃圾進，垃圾出；偏見進，偏見出（Bias In, Bias Out）。」**

所謂 **演算法偏誤（Algorithmic Bias）**，在生成式 AI 領域中，是指模型在訓練與推論過程中，因為訓練資料集（Training Dataset）本身的樣本分佈不均、歷史文化霸權或商業利益導向，導致模型在面對中性、開放式的提示詞時，系統性地偏好特定性別、族裔、年齡、階級或審美標準，進而複製甚至放大社會既有的不平等與刻板印象。

```
【生成式 AI 放大社會偏誤的三階段機制】
階段一：歷史與網路語料失衡（Biased World & Web Data）
        ↳ 網際網路圖庫與新聞中，高階主管多為白人男性、醫護多為年輕女性、商業人像充斥修圖濾鏡
          ↓（模型吞吐數十億筆未經平衡的原始數據進行訓練）
階段二：機率分佈的「多數霸權收斂」（Statistical Mode Amplification）
        ↳ 模型為了降低預測誤差，將「出現頻率最高的特徵（例如 70%）」在生成時放大為「99% 的預設輸出」
          ↓（生成影像與文本回流至社群網路與教育現場）
階段三：刻板印象的自我實現與規訓（Reinforcement & Social Conditioning）
        ↳ 閱聽大眾與下一代將 AI 產出的「統計平均值」誤認為「理想標準」，進一步抹殺多元性
```

如上方架構所示，生成式 AI 不僅僅是「如實反映」現實世界的偏見，它更是一個 **「偏見放大器（Bias Amplifier）」**。在統計學上，當訓練資料中有 65% 的「執行長（CEO）」照片是白人中年男性時，模型在一般預設參數下進行抽樣生成時，為了追求最穩妥的高機率特徵，往往會產出高達 95% 以上的白人男性形象，將原本 35% 的女性與少數族裔領導者在視覺表徵上徹底抹除。

在數位內容設計實務中，最常出現的演算法偏誤可歸納為以下四大類型：

偏誤類型維度	觸發情境與中性提示詞範例	AI 預設產出之典型偏誤表現	對數位傳播與社會價值之潛在危害
性別與職業角色偏誤（Gender & Occupational Bias）	輸入 一位傑出的科學家 、 企業總裁 vs. 一位溫柔的護理師 、 家政人員	前者幾乎全數生成穿白袍或西裝的男性；後者則清一色生成年輕女性。	固化「男主外、女主內」與職業性別隔離，削弱女性在 STEM 科技領域與男性在照護領域的社會能見度。
族裔與西方中心視角（Western-Centric & Racial Bias）	輸入 幸福的現代家庭 、 具有領導力的人 vs. 需要援助的貧困社區	正面現代化場景預設為歐美白人與美式郊區；貧困與混亂場景則高度集中於特定深膚色族裔。	將「現代文明與成功」與西方白人劃上等號，並對全球南方（Global South）形成單一的負面刻板標籤。
單一審美霸權與容貌規訓（Beauty & Age Standardization）	輸入 一位 25 歲的專業女性 、 陽光活力的青年	自動套用高鼻樑、大眼睛、毫無毛孔的平滑白皙皮膚、柔順直捲髮與精緻妝容的「網紅濾鏡」。	將商業修圖軟體打造的虛假完美外貌奉為圭臬，引發青少年與兒童嚴重的容貌焦慮與自我否定。
在地文化與地景失真（Cultural Homogenization）	輸入 台灣的傳統市場攤販 、 亞洲大學生的宿舍生活	混雜日式燈籠、中式古典飛簷或歐美寬敞公寓，缺乏真實台灣鐵皮屋頂、磁磚與外宿套房細節。	抹殺在地文化的獨特肌理，產出四不像的「東方主義（Orientalism）」拼貼罐頭圖，令在地受眾瞬間出戲。

從上表可以清楚看出，如果內容設計師在撰寫提示詞時偷懶，只輸入幾個籠統的名詞，就等於是把作品的「價值觀主導權」拱手讓給了矽谷科技巨頭的訓練資料集。

1.2 真實案例深究：當公立小學把 6 歲女孩的臉餵給 AI——「25 歲的妳」是誰定義的未來？

為了讓同學們深刻體會演算法偏誤並非遙遠的工程問題，而是已經直接衝擊我們日常生活、教育現場與人性尊嚴的真實危機，我們特別引介 Facebook 上的一則極具啟發性的國際真實案例，作為本節的核心思辨教材（案例貼文連結：演算法偏見）。

1. 事件來龍去脈：一張色紙剪貼畫 vs. 一張 AI 生成的「25 歲未來照」

這起引發全球數十萬名家長、教育學者與科技倫理專家激烈辯論的事件，源於美國南卡羅來納州一位母親 Nikki Anderson（Instagram 創作者 `@moms.who.write` ）的親身經歷：

她年僅 **6 歲** 的女兒 Harper 在公立小學參加了一場主題為「長大後的我（Future Career）」的課堂活動。小女孩在課堂上發揮想像力，親手用彩色美術紙剪貼（Construction-paper collage）創作了一幅自畫像——在孩子純真的剪紙作品中，她有著自己原本的棕色頭髮、穿著藍色的工作服、脖子上掛著粉色聽診器，臉上帶著質樸燦爛的笑容，因為她長大後想成為一名照顧病人的護理師（Nurse）。

然而，當 6 歲的女兒放學回家、從書包裡拿出作業時，母親卻震驚地發現：學校老師在 **完全沒有事先告知家長、也沒有取得任何授權同意** 的情況下，擅自拍下 6 歲女兒的臉部照片，上傳到第三方生成式 AI 應用程式中，下指令讓 AI 生成了一張 **「預測她 25 歲擔任護理師時」的超擬真合成照片**，並將這張 AI 照片與小女孩親手做的色紙剪貼畫釘在一起讓孩子帶回家。

更令母親感到毛骨悚然與心痛的是：

1. 在那張 AI 生成的「25 歲未來照」中，演算法自動將小女孩原本天生的髮質，「改造」成了符合西方主流商業審美的柔順波浪長髮，並為她套上了無瑕的成人精緻妝容與標準化的亮麗外貌。
2. 年僅 6 歲的女兒看著那張 AI 照片，竟然羨慕地對媽媽說：*「好酷喔！AI 給了我一直很想要的直髮與波浪捲！」*
3. 母親在社群貼文中貼出了女兒純真的色紙剪貼畫，並寫下了這段直擊靈魂的控訴（以下為貼文原話與中譯對照）：

> *"My 6yo came home from public school with an AI generated photo of herself at 25. She is a small human who is literally capable of imagining an entire independent future inside her own head. I cannot get over how cool that is. My child is brilliant. Your children are brilliant. Creative. Clever. Innovative. Inherently compassionate. Empathetic. Joyful. Honest. Curious. Everything.*
> *And they're going to spend the next twelve years being measured, ranked, standardized, and gradually molded into whatever our economy has decided makes a person useful. Can we at least leave their imaginations alone?*
> *Why do adults feel the need to insert a multibillion dollar industry into something children already do better than us? To what? Make it more impressive? More marketable? More worth looking at? I don't think the children are the ones who need help imagining a future."*

> **【中文精譯】 **：「我 6 歲的女兒從公立學校放學回家，帶回了一張 AI 生成她 25 歲模樣的照片。她是一個小小的人類，完全有能力在自己的腦袋裡想像出一個獨立完整的未來，這件事本身就酷得不得了。我的孩子充滿才華，你們的孩子也充滿才華——富有創造力、聰明、具創新精神、天生慈悲、具同理心、快樂、誠實、充滿好奇心。
> 接下來，她們已經要花整整十二年的時間，在體制中被測量、被排名、被標準化，並逐漸被塑造成我們的經濟體系所認定的『有用之人』。 **我們能不能至少放過她們的想像力？**
> 為什麼大人們總覺得有必要把一個價值數十億美元的龐大科技產業，強行塞進一件孩子們本來就做得比我們更好的事情裡？到底是為了什麼？為了讓它看起來更令人驚豔？**更具市場賣相（More marketable）？更值得被觀看？我不認為需要別人幫忙想像未來的，是這些孩子。 **」

2. 課堂深度思辨：從「6 歲女孩的 AI 未來照」剖析四大倫理與偏誤維度

這起看似只是「國小老師想用 AI 增加課堂趣味」的日常小事，實則像一面照妖鏡，完整映照出生成式 AI 在 **審美規訓、想像力殖民、職業刻板印象與生物識別隱私** 上的四大深層危機。

在課堂上，我們將引導同學從以下 **四個核心討論方向** 展開深度交鋒：

```
【「6 歲女孩的 25 歲 AI 未來照」四大課堂思辨維度】
維度一：審美霸權與身體規訓（Beauty Standardization Bias）
        ↳ 為什麼 AI 預測的「長大成材」，是自動抹去孩子天生的髮質與特徵，換上主流商業濾鏡？
維度二：想像力的演算法殖民（Algorithmic Colonization of Imagination）
        ↳ 親手剪貼的色紙畫 vs. 光滑完美的 AI 圖：大人為何崇拜「更具市場賣相（Marketable）」的標準答案？
維度三：職業與性別角色框架（Occupational & Gender Stereotyping）
        ↳ 當輸入「25 歲的護理師」時，模型在服裝、神態與氣質上強加了哪些性別刻板印象？
維度四：未成年生物特徵與知情同意（Biometric Privacy & Informed Consent）
        ↳ 「出於教學或公益善意」，能否成為未經授權將兒童或受訪者正臉上傳商業 AI 模型的免死金牌？
```

1. **討論方向一：【審美霸權與身體規訓】為什麼 AI 認為「美好的 25 歲」必須換掉妳原本的頭髮？**
   - *現象剖析*：當老師將 6 歲女孩的照片與「25 歲護理師」輸入模型時，老師或許並沒有下達「請把她的頭髮拉直、幫她化濃妝」的指令；但擴散模型在潛在空間進行去噪生成時，自動調用了訓練語料中與「25 歲年輕女性／美麗／專業」高度綁定的主流商業特徵。
   - *引發學生思考*：當 6 歲的孩子看著 AI 生成的自己，脫口說出「AI 給了我一直想要的直髮」時，演算法已經在孩子心中種下了什麼樣的價值觀暗示？（暗示她天生的自然特徵是不夠理想的，必須符合演算法定義的「白人主流／網紅標準」才值得被讚美）。在我們設計與 **SDG 3（心理健康）**、**SDG 5（性別平權）** 或 **SDG 10（減少不平等）** 相關的數位內容時，我們生成的視覺主角是否也在無意間複製這種單一審美霸權，加深青少年的容貌焦慮？
2. **討論方向二：【想像力的演算法殖民】色紙剪貼畫 vs. AI 渲染圖——我們為何向「更具市場賣相」低頭？**
   - *現象剖析*：小女孩用色紙剪貼出的自畫像，線條或許歪斜、比例或許不精確，但每一刀裁剪都承載著 6 歲孩童對自我與世界的主體認知；反觀 AI 生成的 25 歲照片，雖然光影逼真、畫質精良，卻是一張毫無靈魂、由數百萬張商業圖庫平均出來的「塑膠樣板」。母親一針見血地問道：大人非要用 AI 取代孩子的手作，難道只是為了讓作品看起來 **「更具市場價值（More marketable）、更值得被觀看」** 嗎？
   - *引發學生思考*：回顧我們在第一章與第六章反覆強調的核心理念—— **「AI 是創意擴增器，而非人類靈魂的替代品」**。在大學專題與行銷設計中，我們是否也曾因為貪圖方便或迷信「AI 畫出來比較漂亮」，

而放棄了自己原本獨特、接地氣卻稍微粗糙的原創構想，任由 AI 把所有組別的海報都變成千篇一律的「高畫質罐頭圖」？

3. **討論方向三：【職業與性別刻板印象】如果今天孩子想當的不是「護理師」，AI 會畫出什麼？**
    - *現象剖析*：在這起案例中，小女孩的志願是「護理師」，這恰好符合傳統性別分工對女性的刻板期待，因此 AI 生成了一位溫柔甜美、妝容精緻的女性醫護形象。
    - *引發學生思考*：假設今天這位 6 歲女孩在色紙上畫的是「我 25 歲想當重機械工地主任」或「消防隊長」，或者一位 6 歲小男孩畫的是「我 25 歲想當幼兒園老師」或「美甲師」，未經調校的 AI 模型會如何呈現他們？模型是否會強行將女性工程師過度性感化，或是在生成男性照護者時出現特徵錯亂？當我們在專題中呈現各行各業的人物時，該如何避免成為性別刻板印象的幫兇？
4. **討論方向四：【生物特徵隱私與知情同意】「我是為你好／為了做公益」就能擅自上傳別人的臉嗎？**
    - *現象剖析*：學校老師之所以把 6 歲學童的照片上傳到第三方 AI 軟體，初衷很可能是為了讓課堂更生動，並未懷抱惡意。然而，人臉屬於高度敏感的 **生物識別資料（Biometric Data）**——密碼被盜可以更換，但一個人的臉部幾何特徵終生無法更換！一旦未成年人的真實臉孔與姓名被上傳至條款不明的免費 AI 伺服器，這些照片極可能被納入下一代模型的訓練集，甚至流入深偽（Deepfake）資料庫。
    - *引發學生思考*：這給了我們執行 SDGs 專題最嚴厲的當頭棒喝！許多同學在進行街頭田野調查、訪談社區長輩、拍攝偏鄉孩童或身心障礙朋友時，常抱持著「我們是在做大學公益專題，把受訪者的照片丟進 Google Flow 或其他 AI 工具改成插畫或動畫沒關係吧？」的心態。請思考：在未取得當事人（或法定代理人）明確的「AI 生成處理知情同意」前，我們有權利將他人的臉孔餵給演算法嗎？

1.3 SDGs 永續傳播的三大倫理地雷：貧窮色情、救世主情結與視覺漂綠

將上述「6 歲女孩 AI 未來照」的省思擴展到整個永續發展與社會倡議領域，我們會發現：當創作者缺乏倫理敏銳度時，使用生成式 AI 製作 SDGs 行銷內容極容易踩中以下 **三大倫理地雷**。這三大地雷不僅會傷害我們原本想要幫助的對象，更會引發社會大眾強烈的反感與抵制：

1. **地雷一：剝削式悲情與「貧窮色情（Poverty Porn）」**
    - **定義與現象**：所謂「貧窮色情」，是指在公益募款或社會倡議中，為了在短短幾秒內刺激觀眾的罪惡感與同情心，刻意使用極端誇張、煽情的視覺手法，展示弱勢群體（如飢餓兒童、獨居長者、無家者或災民）最脆弱、最狼狽、甚至失去人性尊嚴的畫面。
    - **AI 時代的惡化風險**：過去拍攝這類照片尚受限於現實倫理規範；但在今日，部分創作者為了讓第 4 週的主視覺海報「看起來更有視覺衝擊力」，竟然在提示詞中要求 AI 生成「滿臉蒼蠅、衣衫襤褸、眼神絕望哭泣的貧童」或「在垃圾堆中翻找食物的悲慘老人」。這種透過演算法憑空捏造苦難、消費弱勢者尊嚴以換取點閱率或作業高分的行為，在傳播倫理上屬於極度嚴重的剝削與汙名化（Stigmatization）。
2. **地雷二：高高在上的「救世主情結（Savior Complex）」**
    - **定義與現象**：在構圖與敘事上，將外來的倡議者、企業品牌或都市大學生塑造成「帶來光明與拯救的英雄」，而將在地居民、原住民族、農漁民或受助群體描繪成「被動、無知、等待被救援的客體」。
    - **AI 時代的惡化風險**：由於 AI 訓練語料中充斥著早期西方慈善機構的宣傳照，當你要求模型生成「志工協助偏鄉教育（SDG 4）」時，模型極易生成「一位光鮮亮麗的年輕人站在光芒中，周圍環繞著一群

仰望他、面容模糊的弱勢孩童」。這種視角徹底抹殺了在地社群本身的文化智慧與自主韌性。真正健康的永續倡議，必須是 **「平視的賦權（Empowerment）與並肩同行」**，而非由上而下的施捨。

3. **地雷三：虛構生態奇景與「視覺漂綠（Visual Greenwashing）」**
    - **定義與現象**：在第 1 週與第 5 週我們曾談過文案數據上的漂綠；而在多模態時代，更隱蔽的是「視覺漂綠」——運用 AI 生成高度逼真但完全違背自然生態學或工程現實的畫面，誤導受眾以為環境問題已被輕易解決。
    - **AI 時代的惡化風險**：例如某企業實際上只有微幅減少包裝塑料，卻用 AI 生成「整座工廠與摩天大樓被茂密原始熱帶雨林包覆、鯨魚在清澈見底的港口與貨輪共游」的超寫實海報；或是學生專題為了宣傳淨灘，用 AI 合成出「台灣海岸線出現從未見過的奇幻發光珊瑚礁」。當虛構的 AI 奇景被當作紀實宣傳發布時，不僅會傳播錯誤的生態科學常識，一旦被眼尖的網友識破，整個倡議專案將瞬間被貼上「造假詐騙」的標籤。

1.4 課堂探索小活動：5 分鐘「演算法偏見與想像力」小組快閃思辨

請各組點開 Facebook 案例貼文（6 歲女孩的 25 歲 AI 未來照），觀察貼文中的兒童色紙剪貼畫與母親的文字，在組內進行 5 分鐘快閃討論並回答以下兩個問題：

1. **換位思考**：如果你是那位 6 歲女孩的家長，或是你自己在小學時畫了一張「未來的我」，老師卻直接用 AI 生成一張「符合主流網紅審美、磨皮美白、換掉你原本髮型」的 25 歲照片釘在你的畫上，你的第一感受是什麼？你認同貼文中母親所說的「大人為了讓東西更具市場賣相（More marketable），而入侵了孩子的想像力」嗎？
2. **回頭檢視本組海報**：請打開你們小組在第 4 週產出的《SDGs 核心主視覺海報》。誠實地自我詰問：我們海報中的人物或場景，有沒有在不知不覺中也迎合了 AI 的「單一審美濾鏡」、「性別職業刻板印象」或「剝削式悲情（Poverty Porn）」？

1.5 老師的提醒

> **老師的提醒：**
>
> - **千萬別把 AI 的「第一張預設圖」當成「標準答案」**：當你在生圖模型中輸入「一位台灣農夫」或「一位關心環保的大學生」時，模型給你的第一張圖，只是它從龐大網路圖庫中算出來的「最大公約數（統計刻板印象）」。身為創意總監，如果你直接採用這個預設結果，你就放棄了為多元群體發聲的機會。永遠要問自己：「在這張圖裡，誰被代表了？誰又被演算法隱形了？」
> - **同理心不等於賣弄悲情**：在製作 SDGs 專題時，請永遠記住「尊嚴優先原則」。無論你的專題探討的是高齡獨居（SDG 3）、偏鄉教育（SDG 4）還是街友扶助（SDG 1），請把鏡頭焦點放在他們的「生命韌性、專業技藝與真實生活摩擦」，而不是用 AI 捏造一把眼淚鼻涕來情緒勒索觀眾。尊重受眾與當事人的尊嚴，你的作品才會擁有真正的重量。

第二節：虛假資訊防禦與去偏誤實戰——SynthID 水印、反向搜尋與包容性提示工程

理解了演算法偏誤與倫理陷阱之後，一位成熟的數位內容設計師必須掌握具體的技術防禦工具：一方面，我們要學會利用 **Google SynthID** 與 **反向圖片搜尋（About this image）** 來辨識虛假資訊、為自己的 AI 協作資產打上防偽標記；另一方面，我們要學會運用 **去偏誤提示工程（De-biasing Prompt Engineering）**，主動在提示詞中扭轉模型的刻板印象。

2.1 深偽（Deepfake）與多模態幻覺：當「眼見為憑」徹底破產

在傳統傳播學中，「有圖有真相（Seeing is Believing）」曾是新聞紀實與公共倡議的鐵律。然而，隨著擴散模型（如 Imagen 4、Midjourney）與影音生成模型（如 Google Veo 3.1、Sora）達到相片級寫實度（Photorealism），人類社會正面臨一場前所未有的「認識論危機（Epistemic Crisis）」—— **眼見不再為憑**。

在永續發展與公共議題領域，多模態虛假資訊主要以兩種形態造成破壞：

1. **惡意深度偽造（Malicious Deepfakes）與假新聞圖片**：
   不肖人士利用 AI 偽造政治人物或科學家的發言影片，或是生成極具煽動性的假災難照片（例如：偽造某地核電廠爆炸濃煙、偽造北極熊在都市垃圾場死亡的逼真照片）以騙取社群轉發、製造社會恐慌或操弄輿論。
2. **無意的「多模態幻覺（Multimodal Hallucination）」與錯誤引用**：
   許多內容創作者在網路上搜尋專案參考圖時，看到一張極為震撼的「海洋塑膠垃圾島」或「森林大火中的無尾熊」照片，未經查證便直接引用到專題簡報或社群貼文中，宣稱這是今年的真實災情；事後才被網友抓包那其實是另一位網友用 AI 生成的概念藝術圖。一旦倡議團隊把「AI 幻想圖」當成「真實新聞證據」來引用，即便初衷良善，也會立刻摧毀整個專案的科學公信力（回想第五章我們強調的「事實防彈衣」）。

因此，數位內容設計師在「輸入端（引用外部素材）」必須具備火眼金睛的溯源查核能力；在「輸出端（發布自有 AI 作品）」則必須具備負責任的防偽標示技術。

2.2 數位內容的隱形身分證：Google SynthID 技術原理與 C2PA 內容憑證

面對全網氾濫的 AI 生成內容，科技界與傳媒界提出了關鍵的提問： **「我們能不能在 AI 內容誕生的那一刻，就為它植入一張無法被輕易撕毀的『數位出生證明』？」**

目前全球針對 AI 生成內容的防偽與溯源（Provenance），主要發展出三種不同層級的技術方案。其中，由 Google DeepMind 研發並全面部署於 Google AI 生態系的 **SynthID（隱形數位浮水印）**，代表了當代最頂尖的防偽突破。

我們可以透過一個生動的「藝術品防偽」譬喻，來理解這三種技術的本質差異：

【三種 AI 數位內容防偽與溯源機制之比喻】
1. 可見浮水印（Visible Watermark）　　➔ 如同「貼在畫作角落的紙質標籤」
   - 優點：肉眼一眼可見。
   - 致命弱點：破壞畫面構圖美感，且極易被美工刀裁切（Crop）或用修圖工具塗抹移除。

2. 檔案中繼資料（EXIF / C2PA 內容憑證）　➔ 如同「釘在畫框背面的防偽保證書」
   - 優點：由密碼學簽章保護，可完整記錄「由哪個模型生成、經過哪些軟體編修」的履歷。
   - 致命弱點：一旦圖片被上傳至部分社群平台重新壓縮，或被使用者直接「螢幕截圖（Screenshot）」，畫框背面的保證書就會被直接剝離遺失！

3. Google SynthID（隱形數位浮水印）　　➔ 如同「直接混入油畫顏料分子中的隱形螢光同位素」
   - 核心突破：浮水印不是附加在檔案外殼，而是直接嵌入在影像的「像素微觀頻域」、音訊的「聲波頻譜」與文本的「Token 機率分佈」之中！
   - 抗破壞力：肉眼與人耳 100% 無法察覺，不影響任何畫質與音質；即便圖片遭裁切、加濾鏡、調整色彩、JPEG 壓縮甚至跨平台轉傳，專用掃描器依然能精準識別出 SynthID 訊號！

為了讓大家建立系統性的技術認知，下表詳細對比了這三種溯源機制在數位內容設計工作流中的特性：

評估維度	傳統可見浮水印（Visible Watermark）	C2PA 內容憑證與 IPTC 中繼資料（Content Credentials / Metadata）	Google SynthID 隱形數位浮水印（Invisible Digital Watermark）
技術嵌入位置	覆蓋於影像表層角落的半透明圖案或文字	寫入影像檔案標頭（Header）的加密清單與數位簽章	**直接編碼於影像像素空間頻域、音訊頻譜或文本抽樣機率中**
對視覺／聽覺美感影響	**有影響**；干擾畫面構圖與留白，商業海報常需去除	**零影響**；完全不改變畫面像素與音訊內容	**零影響**；微擾動低於人類視覺與聽覺感知閾值，畫質無損
抗裁切與濾鏡修改能力	**極低**；簡單裁切邊緣或局部 Inpainting 即可抹除	**視軟體而定**；若編修軟體支援 C2PA 則保留，否則易中斷	**極高**；經局部裁切、旋轉、調色濾鏡、有損壓縮後仍可檢出
抗螢幕截圖與社群轉傳	高（只要未裁切到角落）	**極低**；螢幕截圖或部分通訊軟體轉發會徹底洗白 Metadata	**高**；只要像素結構與頻率特徵尚存，截圖後仍具高檢出率
本課程對應工具鏈	部分免費生圖工具之強制角標	Google Search「關於這張圖片」、Adobe 生態系、相機硬體	**Imagen 3/4、Nano Banana、Google Flow、Veo 3.1、Lyria 3 Pro、Gemini**

在技術底層，Google SynthID 包含兩個緊密配合的深度學習模型——**「浮水印嵌入模型（Watermarking Model）」** 與 **「浮水印識別模型（Identification Model）」**：

1. **在影像與視訊中（Imagen / Flow / Veo）**：當擴散模型完成反向去噪、將潛在空間特徵解碼為像素影像時，SynthID 會在肉眼不敏感的高頻紋理與色彩通道中，植入一組具有特定數學相關性的微觀像素擾動。當識別模型掃描圖片時，會給出三個等級的信賴度判定：「偵測到 SynthID 水印（確定由 Google AI 生成）」、「未偵測到水印」或「疑似含有水印（可能經過極度劇烈的人工合成修改）」。
2. **在音樂與語音中（Lyria 3 Pro / Vids TTS）**：SynthID 將聲波轉換為時頻圖譜（Spectrogram），在人耳聽覺遮蔽效應（Auditory Masking）範圍內嵌入隱形訊號，即使音檔被轉為 MP3 壓縮或加入背景雜訊，依然能被識破。
3. **在純文字生成中（Gemini）**：文字沒有像素也沒有聲波，SynthID 是如何打水印的呢？回想第三章的「機率幸運轉盤」！當 Gemini 在挑選下一個 Token 時，SynthID 會在不改變語意品質的前提下，利用一組加密雜湊函數微調候選詞的抽樣分數（稱為 Tournament Sampling）。當累積了一定長度的段落後，統計這些被選中詞彙的隱藏分數分佈，就能以極高的統計顯著性判斷這段文字是否出自 Gemini！

更重要的是，Google 目前已將 **SynthID** 與國際跨產業聯盟制定的 **C2PA（Coalition for Content Provenance and Authenticity，內容來源與真實性聯盟）標準** 深度結合。這意味著同學們在本課程使用 Google AI 工具鏈

所產出的海報、音樂與影片，天生就具備了國際最高標準的「負責任 AI 防偽基因」！

2.3 實戰查核利器：Google 反向圖片搜尋、「關於這張圖片（About this image）」與 Google Lens

在日常專案開發與媒體識讀中，當我們在網路上看到一張令人震驚的永續議題照片，或者想驗證一張圖片是否為 AI 生成時，我們可以立即打開瀏覽器，使用 **Google 圖片搜尋（Google Images / Google Lens）** 結合內建了 SynthID 偵測引擎的 **「關於這張圖片（About this image）」** 功能，執行標準三步查核工作流：

```
【Google 反向圖片搜尋與「關於這張圖片」三步查核法】
第一步：以圖搜圖啟動檢索（Reverse Image Search via Google Lens）
        ↳ 於 Google 首頁點擊「相機圖示（Google 智慧鏡頭）」，上傳可疑圖片或貼上圖片網址。
          ↓
第二步：檢視「關於這張圖片（About this image）」面板（核驗三大核心情報）
        ↳ 1. 【AI 生成資訊（How this image was made）】：讀取 SynthID 隱形浮水印與 C2PA/IPTC 標籤！
        ↳ 2. 【首次出現時間（When Google first found this image）】：抓出「拿十年前舊照片充當今日新聞」的移花接木！
        ↳ 3. 【其他網站的使用情形（How other sites use this image）】：比對國際權威通訊社或事實查核中心報導！
          ↓
第三步：搜尋「完全符合的結果（Exact Matches）」與視覺破綻交叉驗證
        ↳ 追蹤圖片最原始的高解析度出處（如攝影師官網、政府圖庫或 AI 算圖論壇），拒絕孤證！
```

透過這套工具，我們在課堂上只需 30 秒，就能完成過去專業調查記者需要耗費數小時才能完成的影像溯源：

- **識破「移花接木」的假災難圖**：許多社群帳號為了賺取流量，會在颱風或地震發生時，貼出一張駭人的淹水或坍方照片。透過「關於這張圖片」查看 **Google 首次索引時間**，若發現該圖早在五年前就已出現在國外論壇，即可一秒戳破謊言。
- **直接讀取 SynthID 與 C2PA 標記**：當你將本課程由 Imagen 3/4 或 Google Flow 生成的海報上傳至 Google 圖片搜尋，點開「關於這張圖片」，系統會直接透過底層 SynthID 掃描器顯示：**「由 Google AI 製作（Made with Google AI）——透過 SynthID 數位浮水印或中繼資料確認」**。

2.4 去偏誤與多元共融提示工程（De-biasing & Inclusive Prompting）

既然我們在第一節已經看清了演算法偏誤的根源，那麼在第四章與第五章的創作流程中，我們該如何主動介入，防止 AI 產出充滿刻板印象或「塑膠網紅感」的作品？

答案就在於將第三章的 **CRISP 結構化框架** 與第四章的 **S-S-L-M 視覺提示維度** 升級為 **「去偏誤與多元共融提示工程（De-biasing & Inclusive Prompting）」**。我們不能只給模型籠統的職業或身分名詞，而必須在提示詞中明確植入 **「三大去偏誤約束法則」**：

1. **法則一：多元表徵與在地文化錨定（Representation & Local Grounding）**
   - *問題*：直接輸入 `一位研究再生能源的科學家` 或 `一個實踐減塑的家庭`，模型會預設產出歐美白人與美式大別墅。
   - *去偏誤解方*：在 **Subject（主體）** 與 **Setting（場景）** 維度中，明確指定台灣在地人口特徵、跨性別／跨年齡組合與真實在地生活空間（例如：指定「30 歲台灣女性綠能工程師與 55 歲資深男性技師並肩協作」、「背景為帶有洗石子外牆與鐵窗花的台北老公寓陽台」）。
2. **法則二：拒絕單一網紅濾鏡，保留「真實生命肌理（Authentic Imperfection）」**

- *問題*：回想第一節「6 歲女孩的 25 歲 AI 未來照」案例！模型預設會將人物磨皮、美白、拉直頭髮並套上商業修圖感。
- *去偏誤解方*：在 **Subject（主體外貌）** 與 **Medium（媒材規格）** 維度中，強制加入反對過度美化的正面與負面約束——明確要求保留 **「真實皮膚紋理、日曬痕跡、自然捲曲或不羈的髮絲、專注工作時微濕的汗水與素顏質感」**（`natural unretouched skin texture, authentic diverse facial features, natural hair without`），讓人物看起來像真實世界中有血有肉的人，而不是塑膠假人！

3. **法則三：以「平視賦權（Empowerment）」取代「俯視悲情（Pity & Savior Complex）」**
   - *問題*：在表現高齡長者、身心障礙者、基層勞工或偏鄉孩童時，模型常預設生成「低頭憂傷、等待救援、處於陰暗角落」的刻板弱勢形象。
   - *去偏誤解方*：在 **Subject（決定性動態与眼神）**、**Setting（相機機位）** 與 **Lighting（光影氛圍）** 中，全面改採 **「水平平視視角（Eye-level shot）」** 或 **「微仰角尊嚴構圖」**，將人物設定為 **「正在主動展現專業技藝、彼此互助合作、眼神堅毅自信」** 的行動主體，並搭配溫暖通透的自然光，徹底杜絕「貧窮色情」與「救世主視角」！

為了讓同學們能在 Google AI Studio 或 Gemini 中直接為小組專題進行「倫理與去偏誤體檢」，以下提供一套標準的 **CRISP 專題倫理審計與去偏誤重構提示詞範本**：

```
[Context & Role]
你是一位專精於「AI 倫理、多元共融（DEI）與永續傳播學」的資深創意總監與紅隊審計專家（Ethical Red Team Auditor）。你深知生成式 AI 模型在訓練資料上存在性別、族裔、年齡、西方中心視角與商業網紅審美等「演算法偏誤（Algorithmic Bias）」，且公益行銷極易誤觸「貧窮色情（Poverty Porn）」、「救世主情結」與「視覺漂綠（Greenwashing）」三大地雷。

[Instruction]
請針對我們小組提交的「SDGs 專題原始主視覺提示詞／畫面描述」與「Campaign 倡議文案」，執行嚴格的倫理與偏誤審計，並提供升級重構方案：
1. 【演算法偏誤診斷】：指出原始描述中哪些模糊詞彙容易誘發 AI 產出性別、年齡、職業刻板印象，或脫離台灣在地脈絡的西方樣板？是否落入了「過度商業美化濾鏡（如 6 歲女孩 AI 未來照案例中的標準化外貌規訓）」？
2. 【SDGs 倡議倫理地雷排查】：檢視畫面與文案是否存在「剝削式悲情（貶低當事人尊嚴）」、「高高在上的救世主說教」或「違背科學事實的視覺漂綠」？
3. 【S-S-L-M 去偏誤與賦權重構】：請結合 S-S-L-M 四維框架，改寫出一組具備「多元表徵、台灣在地真實肌理、自然不完美質感（Authentic Imperfection）與平視賦權視角（Empowerment）」的升級版生圖提示詞与共融文案。

[Project Input Data]
• 專案名稱與 SDGs 目標：[填入組別專案名稱與 SDG 目標，例如：SDG 3 高齡長者數位共融專案]
• 原始視覺提示詞或畫面描述：[貼上第 4 週原始 Prompt 或海報畫面描述，例如：「一位孤單可憐的老奶奶坐在昏暗的客廳裡看手機，年輕志工微笑著教她，畫面感人，高畫質」]
• 原始 Campaign 文案：[貼上第 5 週 Slogan 與概念論述]

[Specification & Product]
請以結構化 Markdown 表格輸出「偏誤診斷 vs. 去偏誤重構對照表」，並提供可直接輸入 Google Flow / Imagen 的中英雙語升級版 S-S-L-M 提示詞。
```

透過這組提示詞，原本「孤單可憐的老奶奶在昏暗客廳等待年輕志工拯救」的刻板悲情畫面，將會被重構為「充滿生命智慧的台灣銀髮長輩，在明亮的社區長青咖啡館中，神采奕奕地用平板電腦與年輕大學生互相交流在地老照片故事，採用平視紀實攝影與自然膚質肌理」——瞬間讓專題的倫理高度與人文厚度躍升數個檔次！

2.5 課堂探索小活動：3 分鐘「真假照片與 AI 水印」快篩挑戰

請各組打開電腦瀏覽器，進入 Google 圖片搜尋（images.google.com），利用 3 分鐘時間完成以下兩項實測：

1. **實測 A（自家海報 SynthID 驗證）**：將你們小組在第 4 週使用 Google AI Studio（Nano Banana）或 Google Flow（Imagen）生成的 SDGs 主視覺海報原圖，拖曳上傳至 Google 智慧鏡頭（Google Lens），點擊 **「關於這張圖片（About this image）」**，觀察系統是否成功識別出「由 Google AI 製作（SynthID 水印）」的標記！
2. **實測 B（網路環境照溯源）**：在網路上搜尋一張宣稱是「近期環境災難」或「奇特瀕危動物」的熱門社群照片，用反向圖片搜尋查出它的 **「首次出現年份」** 與 **「原始出處網站」**，與鄰組分享你們發現了什麼真相。

2.6 老師的提醒

> **老師的提醒：**
>
> - **認識 SynthID 的「防護邊界」**：SynthID 是極為強大的防偽工具，但請同學們記住，它目前主要針對 **Google AI 生態系（Imagen、Flow、Veo、Lyria、Gemini）** 與支援 C2PA 聯盟的夥伴模型生效。如果網路上的一張假圖片是由某個未加入防偽標準的開源模型（如私人微調的 Stable Diffusion）所生成，SynthID 並不會跳出「由 Google AI 製作」的標記。因此，「未檢出 SynthID 水印」不代表該圖就一定是真人拍攝！我們必須將「SynthID 檢測」、「反向圖片搜尋首次出現時間」與「光影物理常理判斷」三者結合，才能築起完整的防偽防線。
> - **主動標示「AI 協作生成」不僅不會扣分，反而能贏得尊重**：很多同學擔心如果在海報或影片角落標註「本視覺由人類創作者結合 Google AI 協同生成」，會不會讓觀眾覺得不夠厲害？恰恰相反！在當今歐盟《人工智慧法案（EU AI Act）》與台灣公部門最新的 AI 使用指引下，**「主動透明揭露（Transparency Disclosure）」** 是負責任品牌的最高榮譽勳章。坦誠告訴受眾：「我們的數據百分之百來自真實官方文獻，而視覺意象則由團隊運用 AI 進行創意合成」，這正是阻絕「漂綠與造假質疑」最無懈可擊的做法！

第三節：PBL 課堂工作坊——SDGs 專題倫理紅隊審計、防偽查核與期中考前總體檢

3.1 把專題資產放上「倫理與真實性手術台」：三大審計防線

進入課堂最後 1 小時的 PBL 小組實作工作坊！這不僅是第七週的實戰演練，更是我們在第 8 週期中考前，對小組專題「概念驗證階段（第 1–7 週）」所進行的最後一次全面體檢。

請各組專案經理（PM）帶領組員，將第 4 週產出的 **《主視覺海報》**、第 5 週收斂的 **《三大數據錨點與 Campaign Slogan》** 以及第 6 週完成的 **《智財合規抗辯書》** 一併攤開，依循以下三道防線進行「倫理紅隊審計（Ethical Red Teaming）」：

```
【PBL 專案倫理與真實性體檢三道防線】
第一道防線：【演算法偏誤與多元共融防線（De-biasing & DEI）】
            ↳ 檢視視覺與文案是否落入性別、年齡、外貌標準化（如 6 歲女孩 AI 照案例）或文化失真？
第二道防線：【人性尊嚴與反漂綠防線（Anti-Poverty Porn & Anti-Greenwashing）】
            ↳ 檢視是否消費弱勢悲情、流露高高在上的救世主說教，或誇大虛構不實的環保成效？
第三道防線：【防偽溯源與透明揭露防線（SynthID & Responsible AI Disclosure）】
            ↳ 驗證自有素材之 SynthID 訊號、查核外部圖片出處，並擬定正式《AI 透明揭露聲明》！
```

3.2 任務一：演算法偏誤誘發實驗與專案去偏誤重構（25 分鐘）

為了親眼見證演算法偏誤如何在不知不覺中影響創作，請各組在 Google AI Studio 或 Gemini / Google Flow 中執行以下兩步對照實驗，並記錄於本週實作單（ **`SDGs_專題生成內容倫理偏誤審計與SynthID防偽查核單.docx`** ）：

1. **第一步：預設提示詞「偏誤誘發實驗（Bias Elicitation Test）」（10 分鐘）**
   - 請針對你們小組的 SDGs 主題，故意輸入一句 **「極度簡短、未加任何多元與在地約束的籠統提示詞」**（例如： `A successful sustainable leader` 、 `A person who needs help in society` 、 `A 25-year-old nurse / engineer` ）。
   - 觀察模型預設產出的圖像或描述，結合第一節林頌堅老師分享的 Facebook「6 歲女孩的 25 歲 AI 未來照」案例，分析模型在 **「性別、族裔、年齡、外貌濾鏡（如自動美白磨皮、改變髮質）與社經地位」** 上出現了哪些預設偏見？如果將這種預設結果直接用於教育或倡議，會對目標受眾的自我認同與想像力造成什麼負面影響？
2. **第二步：本組專題海報與文案之「去偏誤與賦權重構」（15 分鐘）**
   - 調用 2.4 節的「CRISP 專題倫理審計與去偏誤重構提示詞」，檢視你們第 4 週的主視覺海報與第 5 週的 Campaign 文案。
   - 運用 **「在地文化錨定」、「保留真實自然肌理（Authentic Imperfection）」與「平視賦權視角（Empowerment）」** 三大法則，修正原本可能存在的刻板印象、說教口吻或悲情剝削，產出升級版的視覺提示詞與共融倡議文字。

3.3 任務二：SynthID 防偽檢核、反向搜尋溯源與《負責任 AI 透明揭露聲明》擬定（20 分鐘）

接著，請各組針對專案中的素材進行真實性查核與透明度制度化建設：

1. **自有與外部素材防偽溯源查核**：
   - 使用 Google 圖片搜尋之「關於這張圖片（About this image）」功能，檢測本組由 Google AI 生成之主視覺海報是否具備 SynthID / AI 生成標記。
   - 若專題中有參考或引用任何外部網路新聞圖片、統計圖表，請執行反向圖片搜尋，記錄其「首次索引年份」與「原始權威發布機構」，確保零假圖、零移花接木。
2. **撰寫本組專屬《負責任 AI 創作與透明揭露聲明（Responsible AI Disclosure Statement）》**：
   - 為你們的 SDGs 專題擬定一段約 60～80 字的正式透明揭露聲明（此聲明將於第 10 週正式放入活動網頁頁尾 Footer，並於第 16 週期末發表展示）。
   - **聲明撰寫示範範本**：

     > *「【負責任 AI 創作與透明揭露聲明】：本專案（《格外美好》SDG 12 倡議計畫）之核心視覺意象係由專案團隊主導構思，運用 Google Imagen / Flow 多模態模型協同生成並經人工後製編排，內含 SynthID 數位防偽浮水印；全案所引用之糧食損耗統計數據與政策論據，100% 溯源於農業部與聯合國糧農組織（FAO）真實官方文獻（經 NotebookLM 知識接地核驗），絕無虛構數據或誇大漂綠。」*

3.4 任務三：課堂 3 分鐘「倫理紅隊突襲（Ethical Red Teaming）」同儕互評（15 分鐘）

在課堂最後 15 分鐘，我們將延續上週模擬法庭的熱血精神，展開一場 **「倫理紅隊同儕互評」**！

兩兩小組交換審視彼此的專題海報、Slogan 與剛剛寫好的透明揭露聲明：

- **紅隊稽核員（攻擊／挑刺方，90 秒）**：從最嚴格的「多元共融（DEI）觀察家」與「反漂綠公民記者」角度出發，指出對方作品中潛藏的倫理盲點（例如：「你們的海報雖然關心外籍移工，但畫面中的移工全部低著頭、表情悲苦，這是不是落入了第一節講的『貧窮色情與刻板弱勢標籤』？另外你們的口號宣稱參加活動就能拯救地球，有沒有誇大漂綠的嫌疑？」）。
- **藍隊創意總監（防禦／重構方，90 秒）**：展示本組在任務一中完成的「去偏誤重構方案」與任務二的「真實文獻溯源＋透明揭露聲明」，說明團隊如何透過平視賦權視角與真實數據錨點化解倫理風險。

完成攻防後，由授課教師與助教進行當堂查核簽章！

3.5 迎戰第 8 週期中考：第 1～7 週「基礎探索與觀念驗證」核心知識總體檢

完成本週的倫理與防偽查核後，恭喜全體同學！你們已經完整走完了本課程第一大階段——**「階段一：基礎探索與觀念驗證（第 1–8 週）」**的所有理論學習與工具實戰。

為了協助大家在下一週（第 8 週，11/4）的期中考中游刃有餘、融會貫通，下表為大家將前七週的核心理論、Google AI 工具鏈與專題資產沉澱進行了全局總整理：

週次與章節主題	核心理論與方法論考點	實戰 Google AI 工具與關鍵技術	小組 PBL 專題累積資產
第 1 週 課程介紹與專題引導	• AI 為「創意擴增器」，設計師為「創意總監」 • 議題行銷 **同理心三階法則（Feel ➔ Understand ➔ Act）** • 破除道德說教，見微知著鎖定日常痛點	Google AI 工具生態系全貌觀摩（Vids / Flow 永續敘事標竿拆解）	《SDGs 專案方向初步設定單》（確立組別、分工、目標 TA 與核心主張）

週次與章節主題	核心理論與方法論考點	實戰 Google AI 工具與關鍵技術	小組 PBL 專題累積資產
第 2 週 AI/ML 原理與思辨	• **傳統規則系統（Rule-based）vs. 機器學習（ML）** 之輸入輸出翻轉 • AI ⊃ ML ⊃ DL ⊃ GenAI 四層包含關係 • **蘇格拉底式提問六大維度**（澄清、前提、證據、多視角、後果、反思）	**Google Gemini**（角色反轉設定 System Prompt，執行蘇格拉底式反詰思辨）	《SDGs 議題之 Gemini 蘇格拉底思辨紀錄表》（破除表面直覺與盲點）
第 3 週 生成式 AI 原理與提示工程	• LLM **自迴歸（Autoregressive）Token 機率預測** 本質与上下文視窗 • 解碼參數控制： **Temperature**（貧富差距）、**Top-k**、**Top-p**（核取樣） • **CRISP 結構化提示架構** 與 **Few-shot 少樣本示範**	**Google AI Studio**（透明參數滑桿、System Instructions 全域約束、意圖分類器）	《SDGs 結構化提示工程與多情境資料擴展實作單》
第 4 週 多模態影像生成與視覺提示	• **擴散模型（Diffusion Model）** 正向加噪與反向去噪原理、Seed 與 CFG Scale • **S-S-L-M 四維視覺提示架構**（主體動態、場景構圖與負空間、光影氛圍、媒材規格）	**Google AI Studio (Nano Banana 2 Lite) + Google Flow (Imagen 4 / Inpainting)**	《SDGs 專題核心主視覺生成與模型調校實作單》及專題核心主視覺海報
第 5 週 AI 輔助創意發想與內容規劃	• 閉卷通用模型幻覺（Hallucination）vs. **知識接地（Grounding / RAG）** 開卷考心智模型 • 黃金三角知識庫（官方年報＋學術論文＋常民社群摩擦力） • **洞察萃取四層轉譯階梯（Fact ➔ Tension ➔ Insight ➔ Campaign Idea）**	**Google NotebookLM**（文獻上傳索引、行內引註 `[1]` 跳轉核驗、階梯提示詞庫）	《SDGs 專題權威文獻洞察萃取與 Campaign 企劃收斂單》（三大數據錨點＋20字 Slogan）
第 6 週 生成內容的法律與 AI 著作權	• **人類創作性控制（Human Creative Control）** 為取得著作權之唯一基石 • 輸入端 vs. 輸出端侵權（接觸＋實質相似）、**思想與表達二分法**（風格不受保護） • **商業合理使用（Fair Use）四大黃金準則**（以「轉化性使用」為核心）與 Google IP Indemnification	**Gemini + Google Search Grounding**（即時檢索真實法院判例與智財局函釋，杜絕法規幻覺）	《SDGs 專題生成內容智財合規查核與模擬法庭攻防單》（含人類創作歷程證明）
第 7 週 生成內容的倫理與偏誤查核	• **演算法偏誤（Algorithmic Bias）** 成因與四大維度（含「6 歲女孩 AI 未來照」審美規訓與想像力反思） • SDGs 三大倫理地雷（貧窮色情、救世主情結、視覺漂綠） • **去偏誤與賦權提示工程**、內容溯源（C2PA vs. SynthID）與主動透明揭露	**Google SynthID + Google 反向圖片搜尋（About this image）** + 去偏誤提示詞重構	《SDGs 專題生成內容倫理偏誤審計與 SynthID 防偽查核單》（含負責任 AI 揭露聲明）

3.6 老師的課堂點評與真心話

> **老師的真心話：**
>
> - **別讓 AI 替你決定「什麼叫做美、什麼叫做成功」**：今天我們討論的那位 6 歲小女孩，用色紙剪貼出自己夢想中的護理師模樣，那份笨拙卻真摯的原創力，是任何價值數十億美元的超級電腦都算不出來的。老師希望你們在未來的創作路上永遠保持這份警醒—— **你可以用 AI 來加速排版、測試光影、檢索文獻，但永遠不要讓演算法的「平均值」奪走你對這個世界獨特的觀察、批判與想像力！**
> - **走完前七週，你們已經不再是普通的 AI 使用者了**：回頭看看你們從第 1 週到今天所累積的七份專題實作單——你們懂得用蘇格拉底提問挖掘痛點、懂得調校 Temperature 與 CRISP 架構、懂得用 S-S-L-M 駕馭擴散模型、懂得用 NotebookLM 萃取零幻覺數據洞察、懂得用 Search Grounding 打贏著作權合理使用攻防，更懂得用去偏誤工程與 SynthID 守護社會倫理。帶著這份紮實的底氣迎戰下週的期中考，老師為你們每一個人的成長感到驕傲！

本章小結與課後任務

核心觀念回顧

1. **演算法偏誤的統計本質：** 生成式 AI 並非客觀中立的裁判，而是反映並放大訓練資料集結構性失衡的「偏見放大器」，常在無形中複製性別職業隔離、西方中心視角與單一網紅審美霸權。
2. **「6 歲女孩 AI 未來照」的四重倫理省思：** 透過林頌堅老師分享的真實教育現場案例，我們深刻反思了「審美標準化規訓」、「商業市場賣相（Marketability）對孩童原創想像力的殖民」、「職業性別框架」以及「未成年人生物特徵隱私與知情同意權」。
3. **杜絕 SDGs 倡議三大倫理地雷：** 拒絕剝削弱勢尊嚴的「貧窮色情（Poverty Porn）」、拒絕居高臨下的「救世主情結（Savior Complex）」、拒絕捏造虛假生態成效的「視覺漂綠（Visual Greenwashing）」。
4. **SynthID 與反向搜尋防偽防線：** 理解 Google SynthID 如何將隱形數位浮水印直接編碼於像素頻域、音訊頻譜與 Token 機率分佈中，具備高強度的抗裁切與抗濾鏡能力；並熟練運用 Google 反向圖片搜尋與「關於這張圖片（About this image）」查核首次索引時間與來源真實性。
5. **去偏誤提示工程與透明揭露：** 結合 CRISP 與 S-S-L-M 架構，以「在地文化錨定」、「保留真實生命肌理（Authentic Imperfection）」與「平視賦權視角（Empowerment）」主動消除偏見，並透過《負責任 AI 透明揭露聲明》建立最高水準的公眾信任。

本週產出與課後檢核清單（Checklist）

請各組 PM 與全體組員在下課後、下週期中考前務必逐一完成以下查核：

- ▢ **完成課堂「6 歲女孩 AI 未來照」案例思辨與偏誤誘發實驗**：記錄未約束 Prompt 下模型的預設偏見表現，並完成四大倫理維度反思。
- ▢ **完成第 4 週海報與第 5 週文案之「去偏誤與賦權重構」**：確認專題視覺與文案已消除刻板印象、貧窮色情與救世主說教，具備平視賦權視角與台灣在地真實感。
- ▢ **完成 SynthID 水印驗證與外部圖片反向搜尋溯源**：透過 Google「關於這張圖片」查驗自有生成圖之 AI 標記，並確認所有外部引用素材皆已查明首次出現年份與權威出處。
- ▢ **擬定本組《負責任 AI 創作與透明揭露聲明》**：完成 60～80 字標準揭露聲明，妥善存檔以備第 10 週活動網頁與期末發表使用。
- ▢ **完成課堂倫理紅隊同儕互評與教師簽章**：記錄對手組別之倫理挑刺重點與本組優化方案，並將《第七週：SDGs 專題生成內容倫理偏誤審計與 SynthID 防偽查核單》Word 檔上傳至課程雲端。
- ▢ **複習第 1～7 週講義迎接期中考**：對照本章 3.5 節之總體檢表，溫習前七週核心理論與工具操作心法。

下週預告

在下一週（第 8 週，11/4），我們將迎來本學期的階段性里程碑—— **【期中考：理論與概念驗證階段綜合評估】 **！

期中考將全面檢驗同學們在第 1 至第 7 週所建立的核心觀念與實戰素養，涵蓋：

- **AI/ML/DL/GenAI 底層原理與解碼參數（Temperature / Top-p / 擴散去噪 / Seed）**
- **結構化提示工程（蘇格拉底提問維度、CRISP 架構、Few-shot、S-S-L-M 視覺四維度）**
- **知識接地與洞察轉譯（Grounding / RAG 開卷考模型、NotebookLM 四層洞察轉譯階梯）**
- **智財法規與社會倫理（人類創作性控制、合理使用四大準則、Search Grounding 判例檢索、演算法偏誤反思、SynthID 水印與反向搜尋溯源）**

期中考結束後，從第 9 週起，我們將正式進入「階段二：策略企劃與網頁原型開發」，運用 Google AI Studio 進行大規模社群情緒極性分析，並在 Gemini Canvas 中親手打造出互動式 SDGs 活動專題網頁！請大家全力以赴備戰期中考，預祝全班同學旗開得勝！

實作工作紙：SDGs 專題生成內容倫理偏誤審計與 SynthID 防偽查核單

本工作單為本週實習評量項目，對應產出之正式 Word 檔案為 **`SDGs_專題生成內容倫理偏誤審計與SynthID防偽查核單.docx`**。請各組結合課堂案例思辨與組別 SDGs 專題資產，完成以下倫理審計與防偽查核紀錄：

評估階段與檢核項目	小組填寫與實作記錄內容（小組共編區）
小組組名與專案名稱	組別：第 _____ 組 ｜ 專案名稱：《_____》
選定之 SDGs 目標	第 _____ 號目標：_____（中文名稱）
案例思辨：「6 歲女孩的 25 歲 AI 未來照」與演算法偏見反思 （Facebook 案例連結）	• **審美規訓與想像力殖民反思**：為何 AI 將 6 歲女孩的色紙自畫像替換為「柔順直捲髮、精緻成人妝容」的標準化外貌？這對兒童自我認同與人類原創想像力有何衝擊？（約 60 字）： • **未成年生物特徵隱私紅線：學校未經家長知情同意將學童臉孔上傳第三方 AI，違反了哪些數據倫理？對本組專題田野採集有何啟示？**
演算法偏誤誘發實驗 （Bias Elicitation Test）	1. **輸入之未約束籠統提示詞（Unconstrained Prompt）**： _____ 2. **AI 預設產出之偏誤特徵觀察**（性別、族裔、年齡、網紅濾鏡或西方樣板）： _____
專案三大倫理地雷自我審計與去偏誤重構 （針對第 4 週海報與第 5 週文案）	• **三大倫理地雷排查**： □ 無剝削式悲情（Poverty Porn） □ 無救世主說教視角 □ 無誇大視覺漂綠 • **S-S-L-M 去偏誤與賦權重構方案**（如何植入台灣在地肌理、保留自然真實特徵 Authentic Imperfection 與平視賦權視角）： _____
SynthID 水印檢測與反向圖片搜尋溯源查核 （About this image 實測）	1. **本組海報 SynthID / AI 標記檢測結果**： □ 成功檢出 Google AI / SynthID 標記 □ 經後製合成，已補充透明揭露標示 2. **外部引用圖片／數據圖表反向搜尋溯源**： 原始發布機構：_____ ｜ Google 首次索引年份：_____ 年 查驗結論：□ 確認為真實權威出處，絕無移花接木或誤引 AI 假圖
專案《負責任 AI 創作與透明揭露聲明》 （Responsible AI Disclosure）	撰寫將放置於第 10 週活動網頁頁尾與期末簡報之正式透明揭露聲明（約 60–80 字，交代 AI 協作範圍、SynthID 防偽與官方文獻數據接地來源）： _____
課堂倫理紅隊同儕互評紀錄 （紅隊突襲 vs. 藍隊重構）	• **對手紅隊稽核員之挑刺焦點**（指出本組潛在偏誤、刻板印象或漂綠風險）： • **本組藍隊總監之防禦與修正回應：**
課堂即時諮詢與審查回饋欄 （授課教師／助教現場查核）	□ 倫理與防偽審核通過 □ 視覺或文案仍具刻板印象需微調 □ 透明揭露聲明需補強 教師／助教指導意見與簽章：_____